

### Modelli generativi

L'ambito di lavoro dei modelli generativi è strettamente legato al concetto di riduzione della dimensionalità.

In termini generali, lo scopo di questi modelli è:

- 1. Contribuire alla riduzione della dimensionalità dei dati.
- 2. Comprendere ed apprendere la distribuzione di probabilità del set di dati.

Dalla distribuzione appresa, sarà potenzialmente possibile generare nuovi campioni di dati similari ai campioni di addestramento.

#### Tra i modelli generativi, sono noti:

- VAE: Variational Auto-Encoders.
- ► GAN: Generative Adversarial Networks.



#### **Premessa**

Le Generative Adversarial Networks sono reti il cui scopo è quello di generare campioni sintetici dalla distribuzione dei dati di input.

Generare perciò campioni nuovi che si avvicinino il più possibile a quelli reali.

#### Casi d'uso:

- Generazione immagini sintetiche.
- Animazione e sintesi di video.
- Trasformazione di immagini.
- Generazione di testo e dialogo.

- Sintesi di suoni e musica.
- Sintesi di dati medici.
- Generazione di modelli 3D.



### **Adversarial Training**

Il concetto che sta alla base delle GAN è, come suggerisce il nome, l'addestramento fra due avversari, due reti neurali.

Nello specifico entrano in gioco due attori:

- ► Generatore: una rete neurale che si addestra a generare input dalla distribuzione appresa, che siano più vicini possibili agli originali.
- Discriminatore: una rete che si addestra a riconoscere se l'input è fake (generato) o reale eseguendo una classificazione binaria.



## **Adversarial Training**

L'Adversarial Training si basa sul fatto che due o più reti si addestrino sfidandosi tra loro e interagendo.

I due blocchi della GAN, generatore e discriminatore «si affrontano»:


- ▶ Il *generatore* cerca di generare input sempre più realistici per ingannare il *discriminatore*. La generazione partirà dalla rappresentazione latente.
- ▶ Il *discriminatore* deve imparare a riconoscere quali sono gli input reali e quali quelli generati dal *generatore*.

Questo tipo di addestramento si basa sull'interazione alternata fra i due singoli modelli dei blocchi.



## Rappresentazione

Generatore e discriminatore sono reti profonde. L'architettura è la seguente:





#### Addestramento

Il **generatore** ha raggiunto un buon risultato nel generare input fake quando il **discriminatore** non è più in grado di discriminare tra *reale* e *generato*.

Il generatore genera input quasi perfetti!

L'addestramento di una GAN viene eseguito in due step alternati:

- 1. Si addestra il **discriminatore D** mantenendo bloccato, *freezed*, il **generatore G**. Gli input fake generate da **G** sono considerate fake.
- Si addestra il generatore G mantenendo bloccato, freezed, il discriminatore D. Le immagini fake generate da G sono considerate reali.





#### Step 1:

Si addestra **D** con un batch di dati etichettati  $x_n$  (reali) e  $x_g$  (fake), dove  $x_n$  sono campioni presi dal dataset di input, mentre  $x_g$  sono immagini generate da **G** con valori random della variabile latente.

#### Step 2:

Si addestra  $\bf G$  usando l'intero modello  $\bf GAN$  ( $\bf G+D$ ) con gli strati di  $\bf D$  freezed (non addestrabili) con un batch di dati  $r_k$  (reali) dove  $r_k$  sono valori random della variabile latente.





#### Come si valuta un addestramento avversario?

L'obbiettivo è raggiungere l'equilibrio quando:

- ▶ **G** genera dati che per **D** siano indistinguibili dalla distribuzione dei dati di training.
- D predice sempre valori Real o Fake con probabilità di 0.5.

#### In poche parole:

Il sistema funziona correttamente se entrambe le loss (sia quella di **G** che di **D**) raggiungono una convergenza e l'accuracy di **D** sta intorno al 50%.



# **GAN**Generare nuovi dati

Ad addestramento terminato, si può sfruttare il modello del **generatore** per generare nuove immagini.


Il passaggio dei dati avviene quindi in una sola direzione nella rete: viene eseguito il solo forward-pass.


Differentemente dai VAE, non occorre avere un encoder che sia differenziabile per generare la rappresentazione latente z.





# **GAN** Esempi











# **GAN** Esempi










# **GAN** Esempi









A.A. 23/24



#### Riferimenti

Di seguito un riferimento utile per l'accesso ad esercitazioni e soluzioni sviluppate con il framework **PyTorch**:

GitHub - udacity: Projects and exercises

Di seguito un riferimento specifico ad esempi di Gan:

GitHub - udacity: Gan

GitHub - udacity: DCGan

GitHub - udacity: Cycle Gan



# Proviamo?

