

Variational Auto-Encoder



Variational Auto-Encoder

Modelli generativi

L'ambito di lavoro dei modelli generativi è strettamente legato al concetto di **riduzione della dimensionalità**.

In termini generali, lo scopo di questi modelli è:

1. *Contribuire alla riduzione della dimensionalità dei dati.*
2. *Comprendere ed apprendere la distribuzione di probabilità del set di dati.*

Dalla distribuzione appresa, sarà potenzialmente possibile generare nuovi campioni di dati simili ai campioni di addestramento.

Tra i **modelli generativi**, sono noti:

- ▶ VAE: Variational Auto-Encoders.
- ▶ GAN: Generative Adversarial Networks.



Variational Auto-Encoder

Premessa

I **VAE** sono un tipo di modello generativo il cui principale scopo è quello di **apprendere la distribuzione dei dati che sono utilizzati in addestramento.**

Un **VAE** addestrato correttamente, avrà appreso una corretta **rappresentazione probabilistica della distribuzione dei dati** di addestramento. Lo spazio latente rappresenterà questa distribuzione.

Con un VAE si vuole:

- ▶ *Identificare le caratteristiche distintive apprese dai dati.*
- ▶ *Rappresentare queste caratteristiche con una distribuzione.*
- ▶ *Apprendere come il variare delle caratteristiche influenza la rappresentazione.*
- ▶ *Generare in maniera ‘fluida’ nuovi dati che seguano le distribuzioni apprese.*



Variational Auto-Encoder

Architettura

I VAE, sono di fatto degli **AE** tradizionale. Sono perciò costituiti da due componenti principali connessi da un *bottleneck*:

- ▶ **Encoder**: trasforma l'input in una sua nuova versione codificata, dimensionalmente ridotta e rappresentata da una distribuzione: in genere una *distribuzione normale multivariata*.
- ▶ **Decoder**: decodifica la versione trasformata dell'input in un output il più simile possibile all'input originale.

Tuttavia, i **VAE** si differenziano dai tradizionali **AE** perché si basano anche sul concetto di distribuzione dei dati:

Campioni simili dovranno generare output simili.



Variational Auto-Encoder

Differenza con gli AE

Un semplice Auto-Encoder, **AE**, comprime la conoscenza in un set di caratteristiche che descrivono l'input. Questo vettore latente di caratteristiche è usato per decodificare l'output.

Un **AE** addestrato su un dataset di cani potrebbe estrarre molteplici caratteristiche da usare per dedurre l'input.

Semplificando a due:

Taglia

-0.0372

0.12

0.24

0.805

0.99



Naso schiacciato

0.002

0.2

0.48

0.711

0.96






Variational Auto-Encoder

Differenza con gli AE


Dalla combinazione dei singoli valori assegnati alle caratteristiche, un **AE** farà la previsione dell'output.

Un **VAE** descriverà le stesse caratteristiche sotto una luce diversa:


I singoli valori non saranno altro che campioni presi da una distribuzione che rappresenta la caratteristica.




-0.0372




0.805



naso schiacciato



0.002




0.711

taglia



Variational Auto-Encoder

Differenza con gli AE




Il decoder di un **VAE** non decodificherà più sulla base di un vettore latente di singoli valori ma di un vettore di campioni estratti dalle singole distribuzioni delle caratteristiche.



Variational Auto-Encoder

Differenza con gli AE

In termini generali, addestrare un **VAE** si traduce nel comprendere quali caratteristiche descrivono al meglio un dato e come ognuna di queste caratteristiche spazia in termini di possibili valori.



Il tutto si traduce nell'apprendere i confini entro i quali 'scegliere un campione' sulla base di una caratteristica.

Facendo questo mi assicuro di non pescare campioni invalidi.

Questo si applica per ogni caratteristica e per la combinazione di queste.

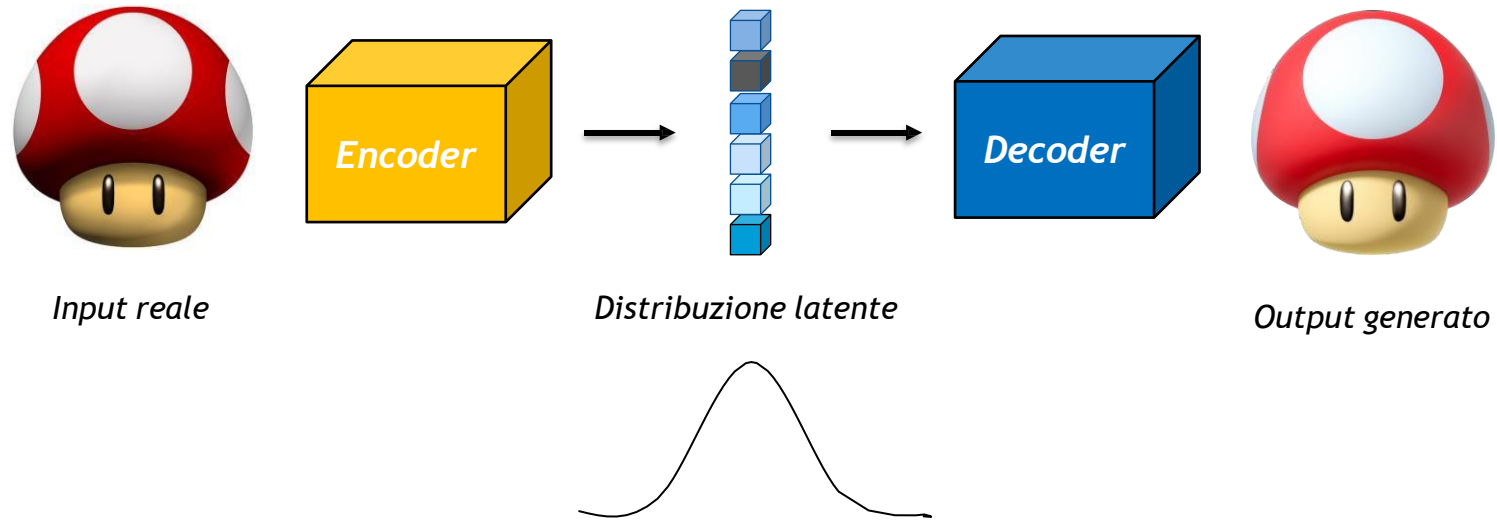


Variational Auto-Encoder

Costruzione

L'idea alla base del VAE perciò è che:

- ▶ **Encoder**: produce una distribuzione latente invece di un vettore latente.
- ▶ **Decoder**: genera campioni che appartengono alla distribuzione latente.





Variational Auto-Encoder

Costruzione

I quesiti che sorgono sono quindi:

Come produrre una distribuzione?

Viene considerata una distribuzione parametrica, in genere gaussiana.

L'encoder è quindi addestrato a stimare i vettori di media e covarianza associati alla distribuzione.



Variational Auto-Encoder

Costruzione

I quesiti che sorgono sono quindi:

Come prevenire la degenerazione?

Viene aggiunto un termine di regolarizzazione alla **loss** che spinge la distribuzione ad essere più vicina possibile ad una distribuzione Gaussiana. Il termine di regolarizzazione è la **KL- Divergence** che misurerà la distanza fra le due distribuzioni.

$$loss = reconstruction\ loss + \lambda * KL_loss$$

Utilizzando questa formulazione si forzerà la distribuzione appresa ad essere simile ad una distribuzione normale: media 0 e deviazione standard 1.




Variational Auto-Encoder

Costruzione

La rappresentazione latente nei **VAE** è costituita da due vettori: *media* e *deviazione standard*.

La matrice di covarianza potrebbe essere una matrice quadrata. Tuttavia per ridurre la complessità di calcolo, si assume che la distribuzione gaussiana abbia matrice della covarianza diagonale. Così si assume implicitamente che le variabili latenti siano indipendenti.






Variational Auto-Encoder

Costruzione

Data la codifica, lo spazio latente conterrà quindi un vettore latente per μ ed un vettore latente per σ .

Il processo di ricostruzione portato avanti dal decoder partirà quindi dalla richiesta di ottenere un **campione** dalla **distribuzione dello spazio latente**.






Variational Auto-Encoder

Costruzione

L'estrazione di un campione da una distribuzione statistica introduce un problema. Questa operazione non è un'operazione deterministica tramite la quale è possibile passare con l'operazione di back-propagation o per il calcolo dei gradienti.




Per superare questo vincolo, si sfrutta una scorciatoia...si applica una tecnica denominata **reparametrization-trick**.



Variational Auto-Encoder

Reparametrization-trick

L'estrazione del campione, \mathbf{z} , dalla distribuzione latente è un'operazione stocastica non attraversabile in addestramento. Per superare questo vincolo, si maschera l'operazione spostandone il contenuto stocastico.




Reference

Anziché estrarre \mathbf{z} da una distribuzione di cui si cerca di apprendere μ e σ , si utilizzerà ϵ , campione estratto da una distribuzione normale fissata. ϵ verrà quindi opportunamente shiftato di un valore μ e moltiplicato da un valore σ .

Variational Auto-Encoder


Reparametrization-trick





Variational Auto-Encoder

VAE



2	3	3	1	0	4	8	2	5	9
2	0	4	0	2	0	0	2	4	
1	5	1	2	7	0	4	3	1	6
3	6	1	6	9	2	2	4	0	8
0	0	9	2	0	3	6	1	2	7
0	4	9	5	9	9	0	3	7	9
9	5	7	2	1	9	7	2	4	7
7	0	5	0	2	0	3	4	4	0
1	0	2	2	4	3	7	4	5	8
4	5	0	9	4	3	0	0	5	2





Variational Auto-Encoder

Riferimenti

Di seguito alcuni riferimenti pratici, in **PyTorch**, che mostrano l'implementazione, e le motivazioni alla base, di un Variational Auto-Encoder:

[GitHub - VAE - 1](#)

[GitHub - VAE - 2](#)

Proviamo?

